Projekt zaliczeniowy – semestr 1, część 1, PDSE – Dawid Masłowski

1. Opis implementacji

1.1 Użyte biblioteki oraz narzędzia Projekt został zrealizowany w języku Python. Do wykonania poszczególnych zadań (od pobierania po analizę i wizualizację) wykorzystano następujące pakiety:

- **BeautifulSoup4** – główne narzędzie do parsowania lokalnych plików HTML i ekstrakcji konkretnych danych (tekstów, linków) ze struktury drzewa DOM.
- **Pandas** – do przechowywania zebranych danych w formie ramek (DataFrames), ich czyszczenia, grupowania i łatwego eksportu do pliku CSV.
- **NumPy** – wsparcie dla operacji na danych i obliczeń statystycznych.
- **pathlib** – do wygodnego i bezpiecznego zarządzania ścieżkami do lokalnych plików HTML.
- **re (wyrażenia regularne)** – pomocne przy zaawansowanym czyszczeniu tekstów i wyciąganiu specyficznych fragmentów stringów.
- **json** – do strukturalnego zapisu wyników w wymaganym formacie JSON z zachowaniem zagnieżdżeń i relacji.
- **matplotlib & seaborn** – do generowania czytelnych wykresów analitycznych oraz map ciepła (heatmaps).

1.2 Strategia scrapingu Zgodnie z założeniami, dane pobierano z wygenerowanych lokalnie plików HTML. Proces podzielono na dwa główne etapy:

1. **Scraping strony głównej (index.html):** W pierwszej kolejności skrypt otwierał stronę główną, na której znajdowała się lista wszystkich ceremonii. Z tego poziomu wyciągano rok ceremonii oraz przypisany do niej link kierujący do konkretnej podstrony w katalogu „pages/”. Stworzono w ten sposób roboczą listę adresów.
2. **Scraping podstron z detalami:** Następnie skrypt iterował po zebranych linkach. Na każdej podstronie zidentyfikowano bloki odpowiadające poszczególnym kategoriom. Dla każdej kategorii pobierano jej nazwę, a następnie listę zwycięzców oraz nominowanych. Kluczowym założeniem było utrzymanie relacji – w trakcie ekstrakcji pilnowano, aby każda osoba/podmiot była na sztywno powiązana z przypisanym do niej filmem, kategorią, rokiem i unikalnym ID ceremonii.

1.3 Obsługa błędów i wyjątków Aby zapobiec przerwaniu działania skryptu w przypadku napotkania braków w strukturze lokalnych plików, zaimplementowano obsługę błędów. Główne obsłużone przypadki to:

- **Brak pliku źródłowego / Błąd ścieżki:** Wykorzystano blok try-except (np. wyłapujący FileNotFoundError), aby skrypt nie kończył się błędem, gdyby brakowało pliku HTML dla konkretnego roku w folderze „pages/”.
- **Brak oczekiwanych tagów HTML (np. brak filmu w nagrodzie specjalnej):** Zastosowano instrukcje warunkowe if, które sprawdzały, czy dany element (np. tag z tytułem filmu) w ogóle istnieje, zanim skrypt próbował wyciągnąć z niego tekst (.text). Jeśli elementu nie było, wstawiano wartość domyślną.
- **Puste wartości tekstowe / Niezgodność typów:** Użyto warunków if do weryfikacji, czy pobrany ciąg znaków nie jest pusty. Pozwoliło to uniknąć błędów w późniejszych funkcjach czyszczących, które wymagały na wejściu danych typu string.

2. Analiza pozyskanych danych

2.1 Kompletność danych

Surowe dane wyciągnięte z HTML wymagały sporo pracy, aby stały się spójne i gotowe do analizy. Podczas procesu kompletowania i czyszczenia rozwiązano m.in. następujące problemy:

1. **Połączone nazwy osób i filmów w jednym ciągu:** W surowych danych często informacje o podmiocie i filmie znajdowały się w jednym rekordzie. Użyto operacji na tekstach, aby rozdzielić te informacje do dwóch osobnych kolumn, co było kluczowe do poprawnego zliczania statystyk.
2. **Różnice w formatowaniu i "śmieci" w tekście:** Zauważono występowanie nadmiarowych białych znaków, znaków nowej linii oraz różnego rodzaju separatorów. Przy pomocy metod stringów oraz biblioteki re usunięto te anomalie, ujednolicono separatory i wyczyszczono nazwy, aby ten sam film nie figurował jako dwa różne wpisy.
3. **Brakujące powiązania z filmami:** Część rekordów (np. nagrody za inżynierię czy nagrody honorowe) w ogóle nie miała przypisanego tytułu filmu. Zamiast je usuwać i tracić dane historyczne, oznaczono takie przypadki odpowiednim znacznikiem, co ujednoliciło strukturę końcowego pliku.

2.2 Statystyki

Dzięki użyciu biblioteki Pandas na oczyszczonym zbiorze, wyliczono następujące statystyki:

- **Całkowita liczba wyekstrahowanych rekordów:** 10 889 (z czego 2 465 to zwycięstwa, a 8 424 to nominacje).
- **Liczba unikalnych encji (osób/podmiotów):** 7 013.

- **Liczba unikalnych produkcji filmowych:** 5 042.
- **Całkowita liczba unikalnych kategorii rozdanych na przestrzeni lat:** 115.

2.3 Znalezione anomalie Historia Oscarów nie zawsze była w 100% spójna. W danych zaobserwowano kilka ciekawych odstępstw od normy:

1. **Wielokrotni zwycięzcy w jednej kategorii (remisy):** Zidentyfikowano aż 63 przypadki, w których w danym roku w jednej kategorii przyznano statuetkę więcej niż jednemu zgłoszeniu, co naturalnie zaburza założenie "jeden zwycięzca na kategorię".
2. **Nietypowa liczba kategorii w pierwszych latach:** W sześciu edycjach (zwłaszcza tych najstarszych) liczba kategorii drastycznie odbiegała od średniej, np. w 1929 roku rozdano nagrody tylko w kilkunastu kategoriach, podczas gdy obecnie jest ich zazwyczaj ponad dwadzieścia.
3. **Kategorie "widmo" (jednorazowe):** Wykryto 17 kategorii, które pojawiły się w historii Akademii zaledwie jeden jedyny raz (często jako nagrody eksperymentalne).

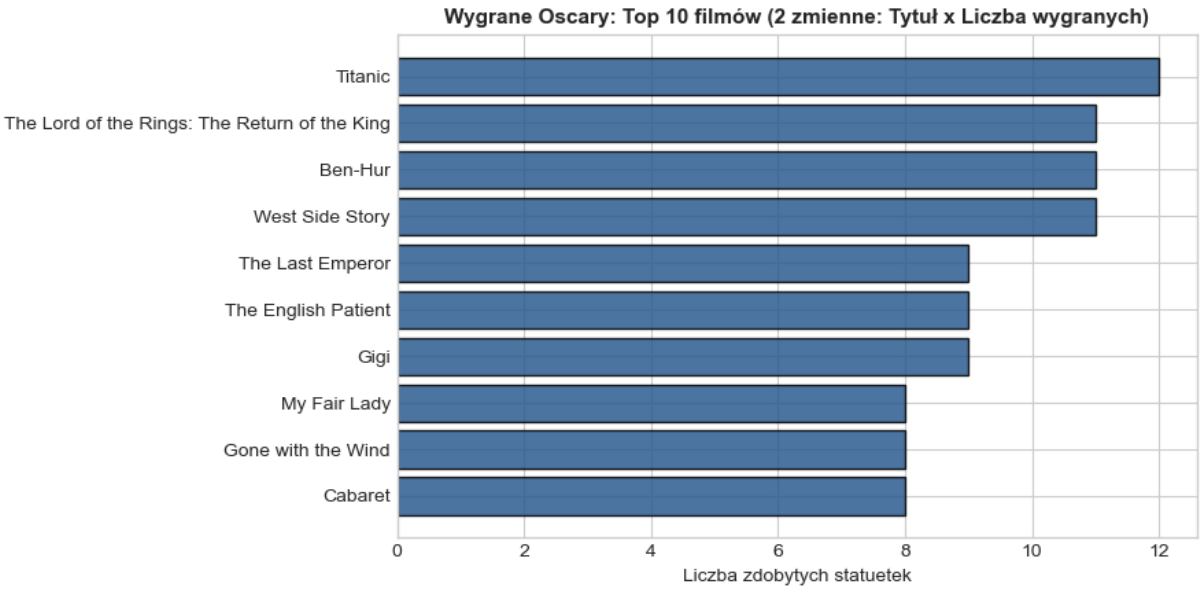
3. Przykłady wykorzystania

3.1 Przykładowe analizy i wizualizacje

Zgromadzone i oczyszczone dane pozwoliły na wygenerowanie szeregu wizualizacji pokazujących trendy i rankingi w historii kina.

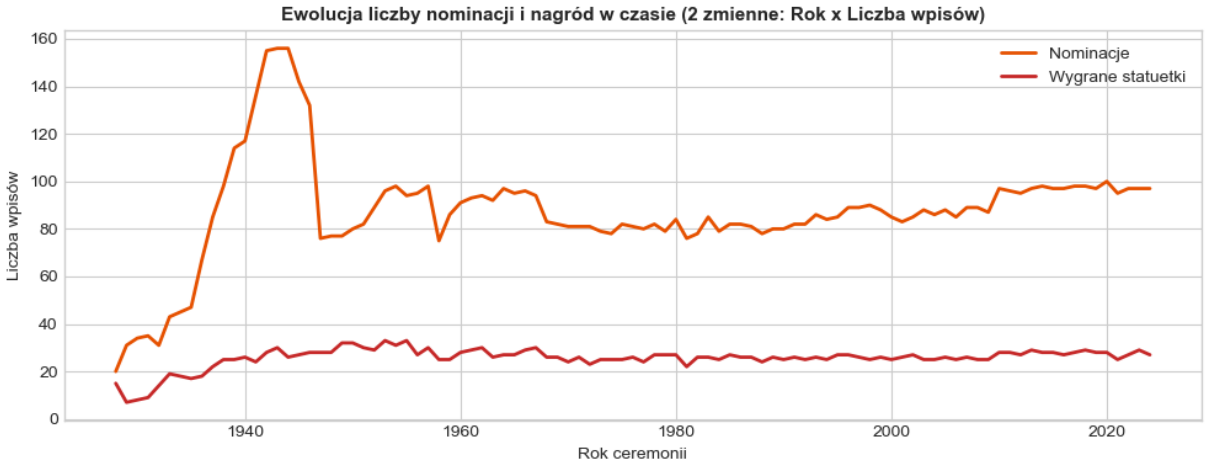
- **Wykres 1: Top 10 filmów z największą liczbą zwycięstw.**

Analiza zliczyła wygrane dla każdego unikalnego tytułu filmowego. Wykres słupkowy dobrze pokazuje, które produkcje zdobyły najwięcej statuetek w swoich latach.



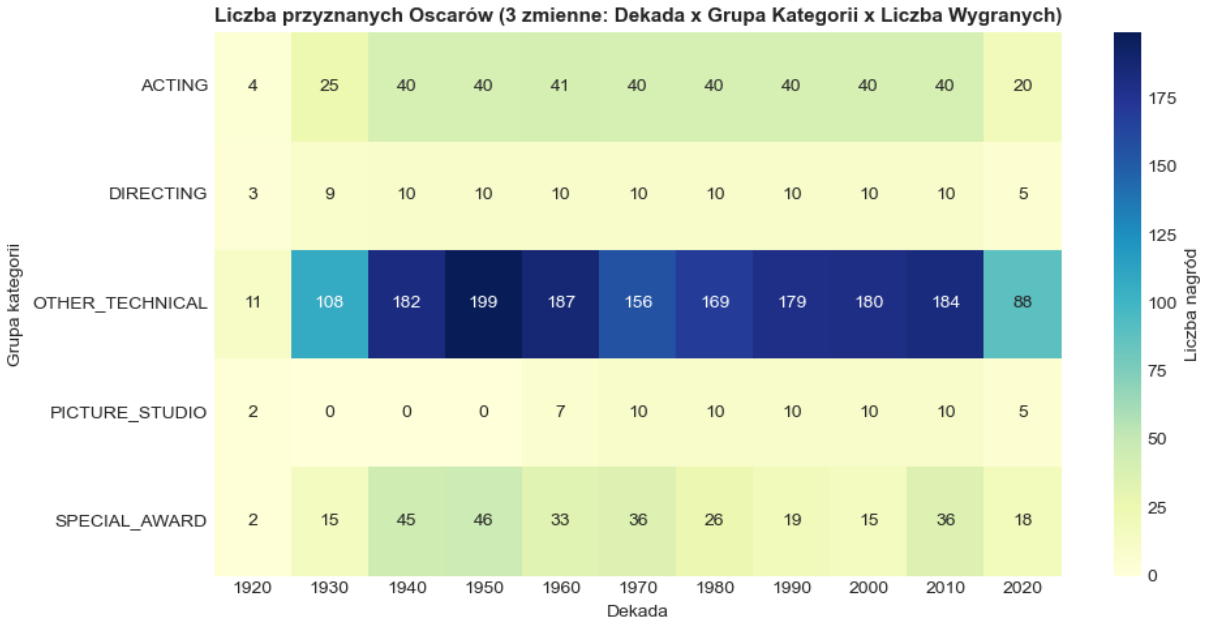
- **Wykres 2: Ewolucja liczby nominacji i nagród na przestrzeni lat.**

Wykres liniowy obrazujący, jak z roku na rok zmieniała się liczba nominacji oraz rozdawanych nagród.



- **Wykres 3: Rozkład zwycięstw w głównych grupach kategorii**

Wygenerowano mapę ciepła (seaborn heatmap), w której osią X są lata ceremonii, osią Y najpopularniejsze grupy kategorii, a intensywność koloru pokazuje gęstość/liczbę nagród. Wizualizacja ta świetnie pokazuje, kiedy dana grupa kategorii miała najwięcej statuetek do wygrania.



3.2 Potencjalne zastosowania

Przygotowany zbiór danych otwiera sporo możliwości na dalsze projekty np.:

- **Analiza historyczna:** Badanie, jak zmieniały się preferencje Akademii na przestrzeni dekad (np. gatunki filmowe, które najczęściej wygrywają w danych okresach).
- **Dashboardy analityczne:** CSV idealnie nadaje się do wgrania do narzędzi takich jak Tableau czy Power BI, aby stworzyć interaktywne raporty dla fanów kina.
- **Modele predykcyjne (Machine Learning):** Używając danych o nominacjach, można próbować budować algorytmy przewidujące przyszłe wygrane.